[8] D. Sarkar and S. Varanasi, "Redis in action: Distributed caching and real-time data processing," J. Syst. Archit., vol. 117, p. 102123, 2021.

[9] UNESCO, AI and Education: Guidance for Policymakers. Paris, France: UNESCO, 2023. [Online]. Available: https://unesdoc.unesco.org/ark:/48223/pf0000376706

[10] M. Alavi and D. E. Leidner, "Knowledge management and knowledge management systems: Conceptual foundations and research issues," MIS Q., vol. 25, no. 1, pp. 107-136, 2001.

[11] F. Paas, A. Renkl, and J. Sweller, "Cognitive load theory and instructional design: Recent developments," Educ. Psychol., vol. 38, no. 1, pp. 1-4, 2003.

[12] X. Zhou, F. Xu, and L. Han, "Deep learning for automatic lecture video generation," IEEE Access, vol. 8, pp. 145321-145330, 2020.

TRUY XUẤT NỘI DUNG VIDEO QUY MÔ LỚN VỚI MÔ HÌNH ĐA PHƯƠNG THỨC TỐI ƯU HOÁ CHO NGỮ NGHĨA TIẾNG VIỆT

Nguyễn Anh Tuấn: tuan.a.nguyen@vpi.pvn.vn

Bộ phận Phân tích Dữ liệu, Viện Dầu khí Việt Nam

CN Trần Nam Khánh*: khanhhbk4a10@gmail.com

Khoa Toán - Cơ - Tin học, Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Hà Nội

Bùi Hữu Phước: phuocbui3102@gmail.com

Khoa Toán - Cơ - Tin học, Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Hà Nội

Nguyễn Trung Thông: thong231203@gmail.com

Khoa Toán - Cơ - Tin học, Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Hà Nội

Nguyễn Thanh Phong: ngphong14@gmail.com

Khoa Công nghệ thông tin, Trường Đại học Hà Nội

Phạm Duy Phương: phuongpd@vpi.pvn.vn

Bộ phận Phân tích Dữ liệu, Viện Dầu khí Việt Nam

*Các tác giả đóng góp như nhau, *: Đại diện liên hệ*

Tóm tắt

Trong thời đại công nghệ số, dữ liệu số bùng nổ, sự gia tăng nhanh chóng của dữ liệu hình ảnh và video đặt ra nhu cầu cấp thiết về các hệ thống truy xuất nội dung thông minh và hiệu quả. Nghiên cứu này giới thiệu hệ thống truy vấn đa phương thức cho phép tìm kiếm và truy xuất sự kiện từ cơ sở dữ liệu video quy mô lớn. Hệ thống kết hợp các mô hình thị giác, mô hình ngôn ngữ lớn, giải pháp truy vấn truyền thống theo từ khoá, truy vấn theo ngữ nghĩa với cơ sở dữ liệu vector để tối ưu hoá quá trình trích xuất thông tin từ dữ liệu lớn. Ngoài ra, việc tích hợp mô hình đa phương thức (multimodal) đã được hiệu chỉnh với ngôn ngữ Tiếng Việt trong quá trình xử lý dữ liệu đã nâng cao đáng kể hiệu quả truy vấn theo ngữ nghĩa. Bên cạnh đó, giải pháp hỗ trợ tìm kiếm dựa trên hình ảnh đầu vào, hình ảnh tham chiếu để cải thiện hiệu quả truy xuất. Kết quả cho thấy hệ thống mang lại hiệu suất cao và khả năng mở rộng tốt trong bài toán tìm kiếm nội dung video quy mô lớn.

Từ khoá: *Truy xuất thông tin từ dữ liệu lớn hình ảnh, Mô hình ngôn ngữ lớn, Mô hình đa phương thức, Tối ưu hóa truy vấn.*

LARGE-SCALE VIDEO CONTENT RETRIEVAL USING A MULTIMODAL MODEL OPTIMIZED FOR VIETNAMESE SEMANTICS

Abstract

In the digital age, the explosion of image and video data creates an urgent need for intelligent and efficient content retrieval systems. This study introduces a multimodal query system that enables search and event retrieval from large-scale video databases. The system integrates vision models, large language models, traditional keyword-based querying, and semantic search using a vector database to optimize information extraction from big data. Additionally, incorporating a multimodal model fine-tuned for the Vietnamese language significantly improves semantic query performance. The system also supports search based on input images or reference images to further enhance retrieval accuracy. Experimental results show that the system delivers high performance and strong scalability for large-scale video content retrieval tasks.

Keywords: *Large-scale image data retrieval, Large Language Models, Multimodal Models, Query Optimization.*

1. Giới thiệu

Với sự phát triển của công nghệ, sự hiện diện ngày càng phổ biến của camera cá nhân, camera giám sát, hành trình cũng như sự gia tăng về các sản phẩm truyền thông số dẫn đến sự tăng trưởng mạnh mẽ của dữ liệu liên quan đến video và hình ảnh. Theo Ceci (2022) [1], trong giai đoạn từ 2019 đến 2022, người dùng đã tải lên YouTube khoảng 500 giờ video mỗi phút, tương đương 82 năm nội dung mỗi ngày, tăng mạnh so với 6 giờ mỗi phút vào năm 2007, tương ứng mức tăng 8.23% trong 15 năm. Việc tái sử dụng thông tin từ các dữ liệu video trở nên quan trọng và đóng vai trò then chốt trong nhiều lĩnh vực như an ninh - xã hội hay thể thao, giải trí. Trong khi các kỹ thuật truy vấn truyền thống tỏ ra nhiều hạn chế khi phải xử lý lượng thông tin lớn, ẩn chứa trong nhiều định dạng khác nhau từ âm thanh, hình ảnh đến chữ viết.

Các giải thuật học sâu tiên tiến đã và đang được phát triển mạnh mẽ, đồng thời chứng minh hiệu quả vượt trội trong nhiều ứng dụng của lĩnh vực thị giác máy tính. Trong đó, bài toán truy xuất khung hình và sự kiện trong video dựa trên mô tả văn bản nổi lên như một hướng nghiên cứu quan trọng, góp phần thúc đẩy sự phát triển của công nghệ truy xuất thông tin đa phương thức. Trước nhu cầu ngày càng cao của người dùng trong việc tìm kiếm và xem lại các cảnh cụ thể từ khối lượng video khổng lồ được tạo ra hằng ngày, việc xây dựng các hệ thống truy xuất video nhanh chóng, thông minh và linh hoạt trên nhiều nền tảng trở thành một yêu cầu cấp thiết trong bối cảnh hiện nay.

Công cụ tìm kiếm đa phương thức dựa trên văn bản (text-based multimodal search engines) hỗ trợ người dùng tìm kiếm nội dung đa phương tiện, bao gồm hình ảnh, video hay âm thanh thông qua các truy vấn bằng ngôn ngữ tự nhiên. Khác với các công cụ tìm kiếm truyền thống chỉ dựa vào thông tin chung (metadata), các hệ thống này kết hợp thông tin văn bản (mô tả, chú thích, từ khóa) với các đặc trưng dựa trên nội dung như hình ảnh, âm thanh, hay dữ liệu ngữ cảnh. Ví dụ, trong truy vấn sự kiện từ video, người dùng có thể hỏi về "MC đang dẫn bản tin giới thiệu về Hồ Hoàn Kiếm". Hệ thống tìm kiếm hoạt động không chỉ dựa trên từ khoá mà còn phân tích nội dung hình ảnh và âm thanh, nhận biết khung hình có chứa người dẫn chương trình trong bối cảnh trường quay. Truy vấn đa phương tiện đồng thời rà soát nội dung bản tin từ nguồn âm thanh có nhắc đến thông tin liên quan từ câu hỏi như Hồ Hoàn Kiếm. Việc phân tích và truy vấn dữ liệu từ nhiều nguồn cải thiện độ chính xác của kết quả dựa trên ngữ cảnh.

Trong thời gian gần đây, các nghiên cứu về mô hình ngôn ngữ - hình ảnh (Vision Language Models) cho thấy khả năng vượt trội trong xử lý đồng thời ngôn ngữ và hình ảnh, học các biểu diễn sâu từ dữ liệu, khai thác mối liên hệ giữa các đặc trưng

của hình ảnh và văn bản. Trong đó, ViT H/14 [14] là một biến thể của mô hình CLIP [13], được huấn luyện từ bộ dữ liệu liên kết hình ảnh và văn bản mô tả tương ứng. Kết quả đầu ra cho phép tạo ra các dữ liệu vector đại diện cho cả hình ảnh và ngôn ngữ. Việc sử dụng mô hình này để tạo ra vector đại diện (embedding) là yếu tố then chốt của các bài toán truy xuất video dựa trên văn bản. Bên cạnh đó, mô hình BEiT-3 [18] cho phép tích hợp sâu giữa ngôn ngữ và hình ảnh sử dụng cơ chế "masked image modeling" giúp học các biểu diễn hình ảnh giàu ngữ nghĩa hay kết hợp ngữ cảnh hình ảnh với văn bản.

Trong bài báo này, chúng tôi đưa ra giải pháp truy vấn tích hợp các mô hình tiền huấn luyện trong các tác vụ khác nhau từ xác định khoảng khung hình, tạo vector đại diện, phát hiện đối tượng từ hình ảnh, nhận diện chữ viết, mô tả khung hình, chuyển giọng nói thành văn bản. Tối đa hoá thông tin trích xuất cho phép đa dạng hóa phương thức truy vấn, tối ưu hoá kết quả tìm kiếm. Giải pháp được ứng dụng trong hội thi Thử thách Trí tuệ nhân tạo Thành phố Hồ Chí Minh 2025 nhằm giải quyết các bài toán truy vấn phức tạp trên lượng dữ liệu video lớn. Các truy vấn bao gồm xác định sự kiện dựa trên đoạn văn mô tả, định vị chuỗi khoảnh khắc liên tiếp trong cùng một video và trả lời câu hỏi. Việc giải quyết các truy vấn với ngôn ngữ tự nhiên trên kho dữ liệu video lớn là thách thức lớn không chỉ về thuật toán tìm kiếm mà còn thử thách khả năng xử lý dữ liệu và tối ưu hoá tài nguyên. Giải pháp sử dụng mô hình AutoShot [22] để bóc tách khung hình từ video. Các mô hình CLIP, BEiT-3 và VietnameseEmbeddingV2 [12] để tạo vector đại diện. YoloV13 [9] được sử dụng để xác định đối tượng từ hình ảnh. Mô hình được hiệu chỉnh cho Tiếng Việt, Vintern-1B-v3.5 [3], được sử dụng để nhận diện chữ cũng như tạo ra mô tả hình. Về xử lý âm thanh, mô hình ChunkFormer [8] cho phép chuyển đổi từ giọng nói sang văn bản với độ chính xác cao. Các thông tin bóc tách từ video được lưu trữ ở hai định dạng chính là thông tin chung (metadata) dưới dạng chữ và dữ liệu vector (dữ liệu chính). Kết quả tìm kiếm thông tin từ nhiều nguồn bao gồm thông tin chung, vector hình ảnh, vector mô tả ảnh được đánh giá và xếp hạng lại để đưa ra danh sách tiềm năng cuối cùng. Việc tích hợp nhiều nguồn truy vấn cho phép kết quả trở nên chính xác hơn đặc biệt trong những câu hỏi có lượng thông tin trùng lặp ở nhiều video khác nhau.

2. Cơ sở lý thuyết

Trong những năm gần đây, truy xuất thông tin từ cơ sở dữ liệu video bằng ngôn ngữ tự nhiên đã trở thành hướng nghiên cứu trọng tâm trong lĩnh vực truy xuất thông tin đa phương tiện. Nhiều công trình đã tập trung vào việc nâng cao khả năng hiểu ngữ nghĩa giữa truy vấn và nội dung video thông qua các mô hình học sâu kết hợp cơ chế chú ý và kiến trúc Transformer. Song (2025) [15] đề xuất mô hình Query-Dependent

DETR (QD-DETR) nhằm tạo biểu diễn video phụ thuộc truy vấn, giúp kết quả dự đoán cho từng đoạn video phản ánh chính xác ngữ cảnh của truy vấn. Trước đó, Liu (2018) [10] giới thiệu mạng Attentive Cross-Modal Retrieval Network giúp nhấn mạnh các đặc trưng hình ảnh liên quan đến nội dung truy vấn và kết hợp hiệu quả ngữ cảnh xung quanh. Gao (2021) [4] sử dụng cơ chế chú ý có hướng dẫn bởi phân bậc ngữ nghĩa để phân tách câu truy vấn thành các cụm từ nhỏ nhằm cải thiện khả năng truy vấn sự kiện trong video chính xác hơn. Trong khi đó, Zhang (2016) [19] ứng dụng mạng LSTM để mô hình hóa mối quan hệ phụ thuộc theo thời gian, góp phần nâng cao chất lượng tóm tắt video. Bên cạnh đó, Zhou (2018) [20] phát triển mô hình sử dụng cơ chế giấu thông tin (masked) kết hợp tự chú ý giúp đảm bảo tính nhất quán giữa việc đề xuất sự kiện và sinh mô tả trong quá trình huấn luyện.

Ở hướng tiếp cận truy xuất dựa trên ngữ cảnh, Hendricks (2017) [6] giới thiệu Moment Context Network (MCN), mô hình truy vấn với ngôn ngữ tự nhiên trong video bằng cách kết hợp đặc trưng cục bộ và toàn cục theo thời gian, đồng thời công bố bộ dữ liệu DiDeMo với hơn 10.000 video cá nhân được gán nhãn chi tiết. Krishna (2017) [7] đưa ra mô hình nhận diện, mô tả đồng thời các sự kiện trong video và cung cấp bộ dữ liệu ActivityNet Captions phục vụ cho tác vụ dense-captioning. Nhằm nâng cao tính ứng dụng, nhiều hệ thống truy xuất video tiên tiến được phát triển nhằm phục vụ các cuộc thi quốc tế như Video Browser Showdown (VBS). Có thể kể đến Vuong (2025) [17] đã giới thiệu View Insight 2.0, Tran (2025) [16] trình bày hệ thống VideoEase, ứng dụng cơ sở dữ liệu vector cùng các mô hình CLIP, BLIP2 và OpenCLIP để mã hóa hình ảnh và truy vấn, tối ưu hóa việc tìm kiếm video quy mô lớn.

3. Phương pháp nghiên cứu

3.1 Kiến trúc hệ thống

Giải pháp được thiết kế gồm hai cấu phần chính: xử lý dữ liệu và truy xuất thông tin. Trong đó, khối xử lý dữ liệu giữ vai trò then chốt trong quá trình trích xuất và chuẩn hóa thông tin từ kho dữ liệu gốc. Các thành phần dữ liệu như khung hình, văn bản, âm thanh được xử lý thông qua các mô hình tiền huấn luyện, nhằm đảm bảo rằng dữ liệu đầu ra được biểu diễn dưới dạng có cấu trúc, dễ dàng tích hợp và truy vấn trong các bước tiếp theo.

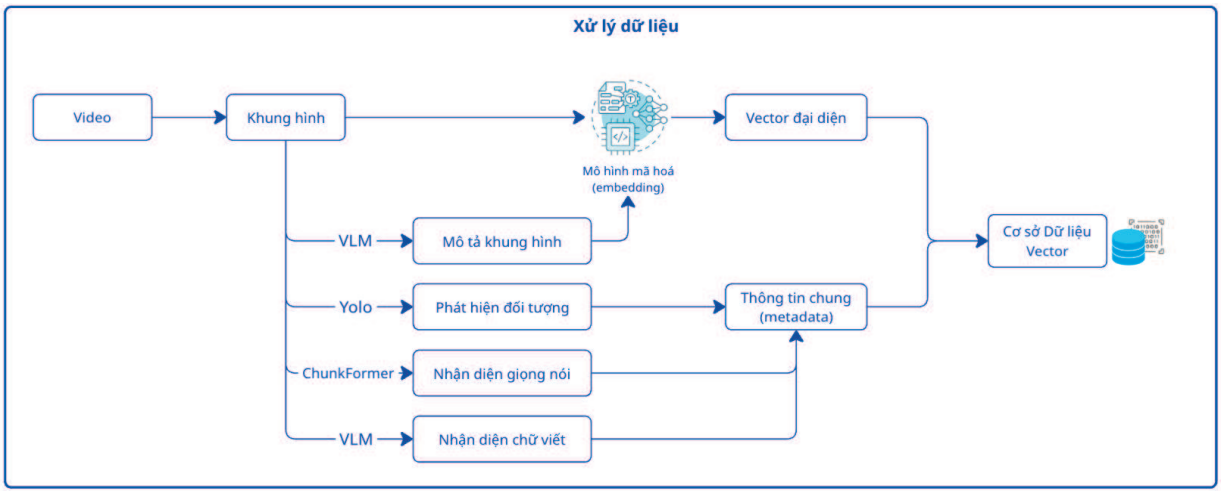

Hình 1. Sơ đồ kiến trúc xử lý dữ liệu

Ở giai đoạn tiếp theo, hệ thống tiếp nhận câu truy vấn dưới dạng ngôn ngữ tự nhiên, sau đó thực hiện phân tích ngữ nghĩa, xử lý câu hỏi và truy vấn thông tin tương ứng. Kết quả trả về bao gồm các khung hình liên quan, vị trí của khung hình trong video, và trong trường hợp truy vấn dạng hỏi - đáp, hệ thống còn sinh ra câu trả lời ngữ nghĩa phù hợp với nội dung truy vấn.

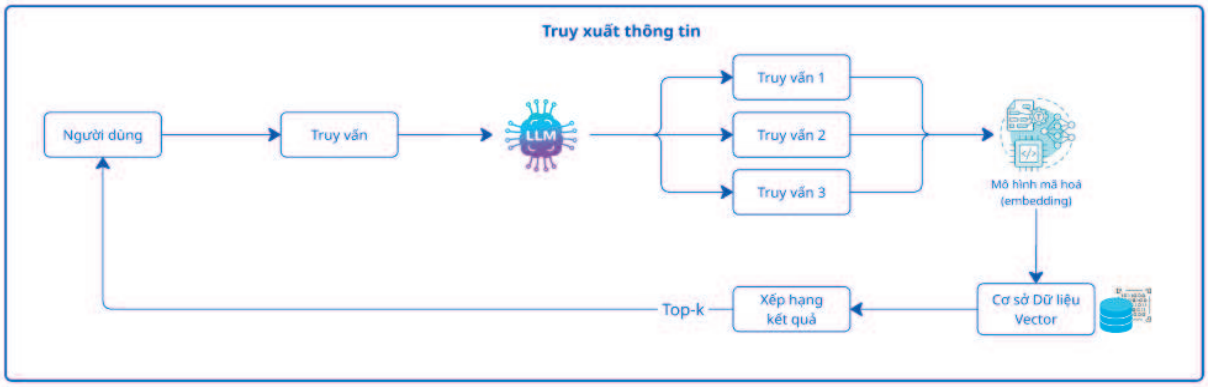

Hình 2. Sơ đồ kiến trúc của hệ thống truy vấn

Hình 2 minh họa kiến trúc tổng thể của hệ thống truy vấn được đề xuất, bao gồm ba mô-đun chính. Thứ nhất, mô-đun tiền xử lý chịu trách nhiệm trích xuất các khung hình (frames) từ video đầu vào. Các khung hình này được biểu diễn dưới dạng vectơ thông qua mô-đun embedding, trong đó có cả đặc trưng hình ảnh, nội dung nhận dạng ký tự quang học (OCR), mô tả ngữ nghĩa của hình ảnh đều được chuyển đổi thành vectơ embedding và lưu trữ trong cơ sở dữ liệu Qdrant.

Thứ hai, mô-đun truy xuất kết hợp các cơ chế tìm kiếm: tìm kiếm theo ngữ cảnh, tìm kiếm theo thông tin trích xuất từ đa mô hình và tìm kiếm theo thời gian. Sự kết hợp này cho phép hệ thống xác định hiệu quả Top-k khung hình có mức độ tương đồng cao nhất với truy vấn của người dùng.

Thứ ba, hệ thống tích hợp API của các mô hình ngôn ngữ lớn (LLMs) như ChatGPT, Gemini nhằm cải thiện chất lượng của truy vấn đầu vào. Các mô hình này được sử dụng để xử lý linh hoạt ngôn ngữ truy vấn (chuyển đổi giữa tiếng Việt và tiếng Anh), diễn giải hoặc tóm tắt nội dung, trích xuất các yếu tố mô tả chính, phân tách truy vấn có cấu trúc tuần tự theo thời gian, và cuối cùng là kết hợp kết quả truy vấn hình ảnh với nội dung ngữ nghĩa để tạo sinh câu trả lời phù hợp với ngữ cảnh

3.2 Giải pháp chi tiết

3.2.1 Trích xuất khung hình đại diện từ dữ liệu

Trong giai đoạn đầu của quá trình xử lý, hệ thống thực hiện tiền xử lý video nhằm trích xuất các khung hình đại diện phục vụ cho các bước truy vấn sau này. Mô hình AutoShot [21] được sử dụng để tự động phát hiện và chọn các khung hình đặc trưng dựa trên sự thay đổi về cảnh, giúp giảm trùng lặp thông tin và tối ưu hóa dung lượng lưu trữ. Mỗi video được chia thành các đoạn ngắn (shots), từ đó chọn ra khung hình đặc trưng nhất phản ánh nội dung chính của từng đoạn. Cách tiếp cận này giúp hệ thống duy trì tính toàn vẹn thông tin thị giác trong khi đảm bảo hiệu suất xử lý và truy xuất cao. Để tối ưu hoá tài nguyên, các khung hình được chuyển đổi sang định dạng WebP, giúp giảm kích thước lưu trữ trong khi vẫn giữ chất lượng hình ảnh phù hợp cho các tác vụ trích xuất đặc trưng.

3.2.2 Trích xuất thông tin đa mô hình

Việc trích xuất thông tin đa mô hình được đề xuất nhằm tăng cường khả năng thu thập các đặc trưng ngữ nghĩa chi tiết mà các vector đặc trưng thông thường dễ bỏ sót. Trong các bài toán liên quan đến truy xuất nội dung video, thông tin văn bản xuất hiện và các đối tượng có trong khung hình đóng vai trò thiết yếu. Dưới đây là các mô hình được sử dụng để trích xuất các thông tin liên quan đến ngữ cảnh:

Nhận dạng đối tượng: Chúng tôi sử dụng mô hình Yolo V13 [9], một trong những phiên bản tiên tiến nhất của họ mô hình YOLO, nổi bật với tốc độ suy luận nhanh và độ chính xác cao. Yolo V13 giúp nhận dạng và định vị các đối tượng trong khung hình ngay cả trong những cảnh phức tạp có nhiều vật thể chồng chéo hoặc di chuyển nhanh. Khả năng xử lý thời gian thực của Yolo V13 đặc biệt phù hợp cho các hệ thống truy xuất thông tin video quy mô lớn, nơi mỗi khung hình cần được xử lý nhanh chóng mà vẫn đảm bảo chất lượng phát hiện.

Nhận diện chữ viết và mô tả khung hình: Chúng tôi áp dụng mô hình Vintern-1B-v3_5 [3], một mô hình ngôn ngữ mô hình ngôn ngữ - hình ảnh được tối ưu để cân bằng giữa hiệu năng và số lượng tham số. Mô hình này thể hiện khả năng vượt trội

trong việc nhận dạng văn bản xuất hiện trong hình ảnh trong thời gian thực, bao gồm chữ tiếng Việt với nhiều kiểu phông khác nhau. Không chỉ dừng lại ở việc nhận dạng ký tự, chúng tôi còn khai thác mô hình ngôn ngữ thị giác để mô tả ngữ cảnh và ý nghĩa tổng thể của khung hình. Mô hình không chỉ đọc được dòng chữ, mà có thể hiểu khung hình đang truyền tải điều gì. Dữ liệu thu được của quá trình được chuyển hóa thành vector đại diện bằng mô hình hỗ trợ tốt cho tiếng Việt là VietnameseEmbeddingV2 và lưu trữ trong cơ sở dữ liệu vector Qdrant.

Nhận diện giọng nói: Để khai thác thông tin ngữ nghĩa từ lời thoại - một thành phần quan trọng trong video, hệ thống tách âm thanh và chuyển lời nói thành văn bản bằng mô hình nhận dạng tiếng nói tự động ChunkFormer [8], được giới thiệu tại ICASSP 2025 và huấn luyện trên 3.000 giờ dữ liệu tiếng Việt. Với tỷ lệ lỗi từ (WER) 8.31%, mô hình này vượt trội so với vinai/PhoWhisper-large (8.85%) và openai/whisper-large-v3 (14.89%) trên các tập dữ liệu công khai [8]. Đối với mỗi khung hình đặc trưng, hệ thống trích xuất đoạn âm thanh trong khoảng 20 giây (10 giây trước và 10 giây sau), chuyển đổi thành văn bản và lưu vào cơ sở dữ liệu nhằm liên kết thông tin lời thoại với nội dung hình ảnh phục vụ truy vấn

3.2.3 Tìm kiếm theo ngữ cảnh

Các mô hình có khả năng hiểu giữa văn bản và hình ảnh là bước nền tảng để ứng dụng truy xuất video. Vì vậy, để xử lý truy vấn với khả năng truy xuất ảnh chính xác, chúng tôi sử dụng mô hình CLIP (với kiến trúc ViT-H-14-378-quickgelu và đã tiền huấn luyện) [13] để trích xuất các đặc trưng hình ảnh với câu truy vấn. Một trong những lợi thế chính của CLIP là khả năng học các mối liên hệ giữa ý nghĩa của mô tả văn bản và ảnh tương ứng, từ đó cải thiện khả năng hiểu mối quan hệ giữa văn bản và dữ liệu hình ảnh.

3.2.4 Tìm kiếm theo thời gian

Hệ thống của chúng tôi sử dụng phương pháp truy vấn theo thời gian cho những câu truy vấn phức tạp, đặc biệt là truy vấn TRAKE của cuộc thi thử thách AI tại Hồ Chí Minh năm 2025. Đây là những câu truy vấn sẽ mô tả một chuỗi các sự kiện: Sự kiện bắt đầu, các sự kiện tiếp theo và sự kiện kết thúc. Hệ thống sẽ phải trả ra một hình ảnh ứng với sự kiện hoặc tất cả hình ảnh trong loạt sự kiện được đề cập.

Phương pháp chúng tôi hoạt động bằng việc tách thành n câu truy vấn, xếp theo trình tự thời gian. Mỗi câu ứng với 1 sự kiện riêng biệt. Với mỗi sự kiện, phương pháp tìm kiếm theo ngữ cảnh và trích xuất thông tin đa mô hình sẽ được áp dụng để chọn ra

top-k ảnh thích hợp kèm theo k điểm số. Lúc này, ta đã có top-nk ảnh của n sự kiện. Ta hình thành các phương án bằng việc chọn ra các ảnh theo trình tự về thời gian. Mỗi phương án sẽ có điểm số bằng tổng điểm các ảnh thành phần. Cuối cùng, thuật toán sẽ sắp xếp lại các phương án theo chiều giảm dần về điểm số để trả lời cho truy vấn.

4. Kết quả nghiên cứu

Giải pháp được triển khai trong hội thi Thử thách Trí tuệ nhân tạo Thành phố Hồ Chí Minh với định dạng tương tự các cuộc thi quốc tế về truy vấn thông tin từ dữ liệu lớn video như Video Browser Showdown (VBS [11]) and the Lifelog Search Challenge (LSC [5]). Các câu hỏi của cuộc thi được phân ra làm ba loại chính bao gồm Textual Known-Item Search (KIS), TRAKE, and Question Answering (Q&A), yêu cầu các phương thức truy vấn khác nhau từ truy vấn từ ngôn ngữ tự nhiên, truy vấn với hình ảnh và hỏi đáp với dữ liệu lớn. Nguồn dữ liệu được thu thập từ các bản tin, chương trình truyền hình, các đơn vị truyền thông như HTV, Báo Thanh Niên, Báo Tuổi Trẻ với ngôn ngữ chính là Tiếng Việt với tổng số 1471 videos tương đương 328 giờ nội dung [2].

Giải pháp ghi nhận độ chính xác 78% trong vòng thi đầu tiên. Trong đó các câu hỏi định dạng KIS chiếm 74%, TRAKE chiếm 13% và QA chiếm 13%. Các câu hỏi KIS mô tả hình ảnh chi tiết thường có kết quả truy vấn tốt với trọng số hình ảnh từ CLIP Embedding cao hơn. Trong khi, một số câu hỏi CLIP Embedding thể hiện không tốt, thay vào đó truy vấn với embedding chữ từ mô tả hình thể hiện kết quả vượt trội. Các câu hỏi TRAKE yêu cầu xác định chuỗi hành động là thách thức lớn nhất khi các hành động cần xác định phải được chỉ ra một cách chính xác cho từng khung hình. Việc xử lý câu hỏi đóng vai trò then chốt khi xác định số lượng hành động từ đó thuật toán tìm kiếm temporal được triển khai để xác định video và trả về chuỗi khung hình liên quan. Nhóm câu hỏi QA yêu cầu kết hợp nội dung tìm kiếm từ cả hình ảnh, chữ viết và âm thanh khi câu hỏi trực tiếp liên quan đến nội dung thuyết minh của video. Dưới đây là một số ví dụ được trích từ vòng thi đầu tiên.

Ví dụ: (KIS) *Đoạn clip bắt đầu với cảnh một tác phẩm điêu khắc cát hoành tráng tại Lễ hội điêu khắc trên cát. Tác phẩm mô tả cảnh những thanh niên chơi thể thao đường phố: một người trượt patin, hai người trượt ván. Nền phía sau là họa tiết vòm cong lớn và có khắc chữ. Tiếp theo có cảnh nhiều tác phẩm khác bằng cát, và có 2 cột khói màu hồng.*

Hình 3. Kết quả truy vấn với câu hỏi dạng KIS.

Ví dụ: (TRAKE) *Đoạn video múa lân một con lân màu vàng đen trắng, tìm các sự kiện sau: E1: Lân quay vòng trên cột số 4 bằng 2 chân trước rồi tiếp đất. Khoảnh khắc đầu tiên mà lân bắt đầu xoay vòng. E2: Khoảnh khắc 4 chân hoàn toàn chạm đất đầu tiên. E3: Khoảnh khắc đầu tiên 2 người biểu diễn lần cuối chào ban giám khảo. E4: Sau đó lân tiến lại chào một con rồng. Khoảnh khắc đầu tiên con rồng cử động đầu.*

Hình 4. Kết quả truy vấn với câu hỏi dạng TRAKE.

Ví dụ: (QA) *Trong đoạn video có 2 câu thơ của một nhà thơ ca ngợi anh hùng Nguyễn Trung Trực trong đình thần Nguyễn Trung Trực tại Kiên Giang. Hai câu thơ đó là gì?*

Hình 5. Kết quả truy vấn với câu hỏi dạng QA. Đáp án của câu hỏi là "Hỏa Hồng Nhật Tảo Oanh Thiên Địa - Kiếm Bạt Kiên Giang Khấp Quỷ Thần".

5. Kết luận và khuyến nghị

Bài báo cung cấp nội dung chi tiết của giải pháp truy vấn sự kiện từ kho dữ liệu lớn video với thử nghiệm trên hội thi Thử thách trí tuệ nhân tạo Hồ Chí Minh 2025. Giải pháp đã phần nào giải quyết hiệu quả những thách thức ngày càng lớn trong công tác quản lý và tra cứu nội dung video quy mô lớn. Chúng tôi đã tích hợp các mô hình thị giác - ngôn ngữ hiện đại (CLIP-ViT-H/14, BEiT3) có tuỳ chỉnh cho ngôn ngữ Tiếng Việt (VietnameseEmbeddingV2) nhằm nâng cao khả năng tìm kiếm dựa vào ngữ nghĩa. Các thông tin tăng cường từ nhận dạng ký tự quang học (OCR), nhận diện giọng nói (ChunkFormer), phân biệt đối tượng và mô tả hình ảnh (Vintern) được sử dụng hiệu quả để định vị video và khung hình từ khối lượng thông tin khổng lồ, giúp cải thiện đáng kể độ chính xác và mức độ liên quan của kết quả tìm kiếm. Giải pháp cũng cung cấp phương án tìm kiếm sự kiện theo thời gian giúp giải quyết hiệu quả các truy vấn liên quan đến chuỗi hành động, sự kiện. Bên cạnh đó, việc sử dụng mô hình VLM Vintern-1.5B đóng vai trò then chốt trong việc nâng cao khả năng tìm kiếm khi cung cấp thông tin mô tả hình chi tiết và chính xác. Thông tin này được sử dụng như một nguồn dữ liệu vector song song với dữ liệu được mã hoá (embed) trực tiếp từ hình ảnh. Nhìn chung, giải pháp cung cấp một bước đệm vững chắc trong việc sử dụng các mô hình tiền huấn luyện nói chung và mô hình đa phương thức nói riêng để nâng cao đáng kể hiệu quả truy vấn sự kiện từ kho dữ liệu lớn.

Mặc dù giải pháp cung cấp các bước ứng dụng rõ ràng với nhiều hứa hẹn, nhưng dữ liệu lớn tiềm ẩn nhiều thách thức như dữ liệu có mức độ tương đồng cao, hay chuỗi sự kiện phức tạp. Giọng đọc vùng miền cũng là một vấn đề cần chú trọng xử lý với tác vụ xử lý âm thanh. Việc sử dụng mức độ tương đồng là phương thức tìm kiếm chủ yếu còn thể hiện một số điểm hạn chế. Việc xây dựng các mối quan hệ dạng đồ thị (graph) để liên kết các sự kiện, đối tượng và dòng thời gian của video là chủ đề hứa hẹn giải quyết được những điểm yếu của truy vấn vector tương đồng. Chúng tôi hy vọng các

phiên bản tiếp theo của giải pháp có thể nâng cao chất lượng khi áp dụng hướng tiếp cận này.

Tài liệu tham khảo

[1] Ceci, L. (2022), 'Hours of video uploaded to YouTube every minute as of February 2020', *Statista*, truy cập ngày 31 tháng 10 năm 2025, từ <https://www.statista.com/statistics/259477/hours-of-video-uploaded-to-youtube-every-minute>.

[2] Do, T.-L., Huynh, V.-T., Nguyen-Quang, T., Nguyen, H.-D., Tran, M.-K., Ninh, T.V., Le, T.-K., Ngo, T.D., Dang-Nguyen, D.-T., Ngo, T.-T. et al. (2024), 'Event retrieval from large video collection in Ho Chi Minh City AI Challenge 2024', *International Symposium on Information and Communication Technology*, tr. 3-17, Springer.

[3] Doan, K.T., Huynh, B.G., Hoang, D.T., Pham, T.D., Pham, N.H., Nguyen, Q.T.M., Vo, B.Q. và Hoang, S.N. (2024), 'Vintern-1B: An Efficient Multimodal Large Language Model for Vietnamese', *arXiv:2408.12480*, truy cập ngày 31 tháng 10 năm 2025, từ <https://arxiv.org/abs/2408.12480>.

[4] Gao, J. và Xu, C. (2021), 'Fast Video Moment Retrieval', *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, tr. 1503-1512.

[5] Gurrin, C., Zhou, L., Healy, G., Bailer, W., Dang Nguyen, D.-T., Hodges, S., Jónsson, B., Lokoč, J., Rossetto, L., Tran, M.-T. et al. (2024), 'Introduction to the seventh annual lifelog search challenge, LSC'24', *Proceedings of the 2024 International Conference on Multimedia Retrieval*, tr. 1334-1335.

[6] Hendricks, L.A., Wang, O., Shechtman, E., Sivic, J., Darrell, T. và Russell, B.C. (2017), 'Localizing Moments in Video with Natural Language', *2017 IEEE International Conference on Computer Vision (ICCV)*, tr. 5804-5813.

[7] Krishna, R., Hata, K., Ren, F., Fei-Fei, L. và Niebles, J. (2017), 'Dense-Captioning Events in Videos', *2017 IEEE International Conference on Computer Vision (ICCV)*, tr. 706-715.

[8] Le, K., Ho, T.V., Tran, D. và Chau, D.T. (2025), 'Chunkformer: Masked chunking conformer for long-form speech transcription', *ICASSP 2025 - IEEE International Conference on Acoustics, Speech and Signal Processing*, tr. 1-5, IEEE.

[9] Lei, M., Li, S., Wu, Y., Hu, H., Zhou, Y., Zheng, X., Ding, G., Du, S., Wu, Z. và Gao, Y. (2025), 'YOLOv13: Real-Time Object Detection with Hypergraph-

Enhanced Adaptive Visual Perception', *arXiv:2506.17733*, truy cập ngày 31 tháng 10 năm 2025, từ <https://arxiv.org/abs/2506.17733>.

[10] Liu, M., Wang, X., Nie, L., He, X., Chen, B. và Chua, T.-S. (2018), 'Attentive moment retrieval in videos', *The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval*, tr. 15-24.

[11] Lokoč, J., Veselý, P., Mejzlík, F., Kovalčík, G., Souček, T., Rossetto, L., Schoeffmann, K., Bailer, W., Gurrin, C., Sauter, L. et al. (2021), 'Is the reign of interactive search eternal? Findings from the Video Browser Showdown 2020', *ACM Transactions on Multimedia Computing, Communications, and Applications*, số 17, tập 3, tr. 1-26.

[12] Nguyen, N.T., Nguyen, N.Q. và Nguyen, V.H. (2025), 'Vietnamese_Embedding: Embedding model in Vietnamese language', truy cập ngày 31 tháng 10 năm 2025, từ <https://huggingface.co/AITeamVN/Vietnamese_Embedding>.

[13] Radford, A., Kim, J.W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J. et al. (2021), 'Learning transferable visual models from natural language supervision', *International Conference on Machine Learning*, tr. 8748-8763, PMLR.

[14] Schuhmann, C., Beaumont, R., Vencu, R., Gordon, C., Wightman, R., Cherti, M., Coombes, T., Katta, A., Mullis, C., Wortsman, M. et al. (2022), 'LAION-5B: An open large-scale dataset for training next generation image-text models', *Advances in Neural Information Processing Systems*, số 35, tr. 25278-25294.

[15] Song, X., Lin, H., Wen, H., Hou, B., Xu, M. và Nie, L. (2025), 'A comprehensive survey on composed image retrieval', *ACM Transactions on Information Systems*, số 44, tập 1, tr. 1-54.

[16] Tran, Q.-L., Nguyen, B., Jones, G.J. và Gurrin, C. (2025), 'VideoEase at VBS2025: An interactive video retrieval system', *International Conference on Multimedia Modeling*, tr. 363-370, Springer.

[17] Vuong, G.-H., Ho, V.-S., Nguyen-Dang, T.-T., Thai, X.-D., Ho-Le, M.-Q., Le, T.-K., Pham, M.-K., Ninh, V.-T., Gurrin, C. và Tran, M.-T. (2025), 'ViewsInsight2.0: Enhancing video retrieval for VBS 2025 with an automatic query generator powered by large language models', *International Conference on Multimedia Modeling*, tr. 371-377, Springer.

[18] Wang, W., Bao, H., Dong, L., Bjorck, J., Peng, Z., Liu, Q., Aggarwal, K., Mohammed, O.K., Singhal, S., Som, S. et al. (2023), 'Image as a foreign language: BEiT pretraining for vision and vision-language tasks', *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, tr. 19175-19186.

[19] Zhang, K., Chao, W.-L., Sha, F. và Grauman, K. (2016), 'Video summarization with long short-term memory', *European Conference on Computer Vision*, tr. 766-782, Springer.

[20] Zhou, L., Zhou, Y., Corso, J.J., Socher, R. và Xiong, C. (2018), 'End-to-End Dense Video Captioning with Masked Transformer', *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, tr. 8739-8748.

[21] Zhu, W., Huang, Y., Xie, X., Liu, W., Deng, J., Zhang, D., Wang, Z. và Liu, J. (2023), 'Autoshot: A short video dataset and state-of-the-art shot boundary detection', *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, tr. 2238-2247.